

1. 테이블

테이블	줄	화면	쓰임
master.area_event	1,787	읽음	주변 동향 카드가 읽는 유일한 테이블
master.urban_notice	43,986	간접	고시 본문 · <code>area_event.body</code> 로 복사
master.g2b_bid	4,698	미연결	공사 발주
master.press_event	213	미연결	정책 발표 (백필 진행 중)
master.sbiz_store	554,092	미연결	층별 임대 · 상권
master.localdata_permit	3,146,365	미연결	층별 임대 · 상권
ref.biz_category	75	미연결	업종 → 상권 7갈래

2. master.area_event

사건 하나가 한 줄. 건물과는 조회 시 반경(기본 700m)으로 만난다.

칸	형	찬 것	값
id	bigserial	1,787	PK
kind	text	1,787	정바·개발 / 기반시설 / 건축 인허가 / 기타
name	text	1,781	이름
on_date	date	1,192	고시일
on_year	smallint	1,736	연도만 아는 것
gosi_no	text	812	서울특별시 고시 제2026-145호
body	text	1,625	고시 본문(요지)
source	text	1,787	국토교통부 국가공간정보 / 서울도시공간포털
source_url	text	1,562	고시문 원문 주소
src_table , src_key	text	1,787	원천 되짚기 (<code>redevel_zone</code> / <code>district_plan</code>)
geom	geometry(Geometry,4326)	1,787	구역 폴리곤 · GIST

3. master.urban_notice

칸	형	찬 것	값
notice_code	text PK	43,986	11110NTC202407120002
notice_no	text	43,986	2026-145
notice_date	date	43,986	1936-09-19 ~ 2026-09-03
title , body	text	43,932	제목 · 본문 요지(중양 280자)
site , charger , phone , classify	text	일부	부서 · 담당 · 전화 · 분류
pdf	text	17,074	고시문 주소 · pdf 11,897 / hwp 5,177
pdf_text	text	788	고시문 원문 글자 (진행 중)
pdf_pages , pdf_issuer , pdf_no	smallint, text	—	쪽수 · 발행 기관 · 원문 고시번호

4. master.g2b_bid — 공사 발주

칸	형	찬 것	값
bid_no	text PK	4,698	공고번호
name	text	4,698	공고명
inst , demand_inst	text	4,698	공고기관 · 수요기관
notice_on , opening_on	date	4,698	공고일 · 개찰일
price	numeric	4,530	추정가격
method , url , official , phone	text	—	계약방법 · 공고 주소 · 담당
station / road / jibun	text	233 / 445 / 2	공고명에서 읽어낸 지명
geom	geometry(Point,4326)	242 (5.2%)	역·도로 이름이 DB에 실재할 때만

5. master.press_event — 정책 발표

본문 칸이 없다. 보도자료 문장은 저장하지 않는다(저작권 · 6장).

칸	형	값
ntt_no	bigint PK	서울시 게시글 번호
on_date	date	발표일
dept	text	담당부서 (도시공간본부 신속통합기획과)
name	text	뽑은 사실로 우리가 지은 이름 — 전농동 152-65 일대 · 신속통합기획
topic	text	신속통합기획 · 모아타운 · 장기전세 · 디자인경관 …
station , road , jibun	text	DB에 실재하는 것만
scale	text	130㎡ · 970세대 · 최고 34층
url	text	원문 링크
geom	geometry(Point,4326)	역·도로 좌표

6. 업체 두 종 · 상권 사전

■ master.sbiz_store · 554,092

칸	값
store_id	PK · 상가업소번호
name , branch	상호 · 지점
cat1/2/3 + _cd	상권업종 대·중·소
ksic	표준산업분류
bldg_mgm	건물관리번호 25자리
pnu	앞 19자리 · 99.6%
floor / floor_no	원문 / 읽은 층 66.3%
is_base	지하인 건 아는데 층 모름
lng , lat , geom	100%

■ master.localdata_permit · 3,146,365

칸	값
kind	업종 slug · 185종
name , biz1 , biz2	사업장명 · 업태 · 위생업태
status / state	원문 28종 / 영업·폐업·휴업·미상
open_on , close_on	인허가일 · 폐업일
area	소재지면적 29.4%
floor_no	주소에서 읽은 층 23.3%
x5174 , y5174	원좌표(EPSG:5174)
lng , lat , geom	변환 좌표 96.5%
영업 980,919	폐업 1,965,397 · 미상 196,308

■ ref.biz_category · 75

source (sbiz|localdata) · key (업종명) · cat (먹자·판매·업무·유흥·생활서비스·교육·의료·기타). 대장 용도로 가르면 「기타」가 50.8%, 이 사전으로 가르면 1.9%.

7. 출처

자료	출처	받는 법	라이선스	상업
정비구역 · 지구단위계획 도형	국토교통부 국가공간정보 (V-World)	SHP 파일 UD602 · UD603 · C_UQ161	표기 CC BY-NC-ND	가능 진흥원 확인
고시 본문 · 고시문	서울도시공간포털 urban.seoul.go.kr	JSON API (POST) 키 불필요	저작권법 제7조 보호 대상 아님	가능
서울시보	서울 열린데이터광장 0A-23063	OpenAPI seoulCnMst 인증키	공공누리 0유형	가능
도시계획시설 도형	서울 열린데이터광장 0A-21129/30/34/41	SHP 파일 EPSG:5174	공공누리 1유형	가능
공사 발주	나라장터 apis.data.go.kr/1230000	OpenAPI 키 · 15일씩	제한 없음	가능
건축 인허가	건축HUB 「인허가」 계열 17장	시군구별 파일 로그인	제한 없음	가능
업체(상권업종)	소상공인시장진흥공단 data.go.kr 15083033	CSV zip · 키 불필요	제한 없음	가능
업체(인허가)	LOCALDATA file.localdata.go.kr	업종별 CSV 208개 키 불필요 · cp949	제한 없음	가능
정책 발표	서울시 보도자료 seoul.go.kr/news	HTML 굵기	공공누리 4유형	본문 금지

8. 저작권

고시 — 그대로 써도 된다

저작권법 제7조가 「국가 또는 지방자치단체의 고시·공고·훈령 그 밖에 이와 유사한 것」을 보호받지 못하는 저작물로 정하고 있다. 고시 본문·고시문 PDF·서울시보는 전문을 저장하고 화면에 실어도 된다. 서울도시공간포털에는 공공누리 표시가 없고 robots.txt 도 없다.

보도자료 — 본문은 못 쓴다

본문 끝에 「공공누리 제4유형: 출처표시 + 상업적 이용금지 + 변경금지」가 붙어 있다. 발탐정은 유료 서비스라 상업적 이용이다. 본문·제목·부제를 저장하거나 화면에 실지 않는다.

넣는다	안 넣는다
위치(역·도로·지번) · 규모(면적·세대·층수)	본문 문장 — press_event 에 body 칸이 없다
발표일 · 담당부서 · 원문 URL	기사 제목 · 부제를 그대로
뽑은 사실로 우리가 지은 이름	고시와 같은 갈래에 세우기 (고시=결정, 이견 발표)

본문은 파싱할 때만 메모리에 두고 버린다. 저작권은 표현을 보호하지 사실을 보호하지 않는다.

더 확실히 하려면 서울시에 별도 이용허락을 받는 길이 있다. 공공누리 4유형이어도 기관이 따로 허락하면 된다.

9. 보도자료 크롤링

항목	값
목록	<code>https://www.seoul.go.kr/news/news_report.do?curPage=N&bbsNo=158</code>
상세	<code>https://www.seoul.go.kr/news/news_report.do?bbsNo=158&nttNo=456622</code>
분량	10건/쪽 · 6,356쪽 ≈ 63,560건 · 3년치는 약 1,400쪽
형식	서버 렌더링 HTML — 번호·제목·담당부서·등록일이 그대로 들어 있다. JS 불필요
robots.txt	<code>Allow: /news</code>
증분	1쪽만 받아 아는 <code>nttNo</code> 가 나오면 멈춘다 → 하루 한 요청
거르기	제목에 개발·시설 낱말이 없으면 상세를 안 받는다 (17%만 통과)
자리	본문에서 역·도로·지번을 뽑아 <code>subway_stations</code> · <code>road_segment</code> 와 대조. DB에 실재하는 것만 인정
스크립트	<code>scripts/press/fetch_press.py</code>

■ 수확 (한 달치 실측)

단계	건	환산
보도자료 전체	295	연 3,500건
개발·시설 관련 (17%)	49	연 600건
자리가 잡힌 것 (22%)	11	연 130건

10. 나머지 원천 받는 법

자료	엔드포인트	주의
고시	<code>urban.seoul.go.kr/ntfc/getNtfcList.json</code> POST · pageSize 100	Referer 필요 · <code>/api/ntfc/...</code> 는 404 서버에 깨진 줄 1개(쪽 쪼개 건너뛴)
고시문	<code>UpisArchive/DATA/PM/pdf/{code}/{파일명}</code>	대소문자 지킬 것 · pdf 70% / hwp 30% 스캔본 섞여 있음
서울시보	<code>openapi.seoul.go.kr:8088/{키}/json/seoulCnMst/1/1000/</code>	4,250호 목록 + PDF 주소 한 호 50~95MB
나라장터	<code>apis.data.go.kr/1230000/ad/BidPublicInfoService/getBidPblancListInfoCnstwk</code>	15일 넘으면 <code>resultCode 07</code> 날짜 <code>YYYYMMDDHHMM</code> · <code>type=json</code>
LOCALDATA	<code>file.localdata.go.kr/file/download/{업종}/info?orgCode=6110000_ALL</code>	브라우저 UA 필수(헤드리스도 403) cp949 · 업종 목록은 페이지에서 뽑음
소상공인	<code>data.go.kr 15083033</code>	전국 zip 344MB · 시도별 17파일 zip 이름은 cp949
도시계획시설	서울 열린데이터광장 0A-21134 외 3종	EPSG:5174 · 미수집
건축HUB	<code>scripts/hub/download_seoul.py --only</code> 인허가	미수집

11. 스크립트

받기	적재
scripts/urban/fetch_notices.py	scripts/load_urban_notice.py
scripts/fetch_notice_pdf.py (받기+적재 겸함)	—
scripts/g2b/fetch_bids.py	scripts/load_g2b.py
scripts/press/fetch_press.py (받기+적재 겸함)	—
scripts/localdata/download_localdata.py	scripts/load_localdata.py
scripts/datagokr/download_datagokr.py -only 15083033	scripts/load_sbiz.py
—	scripts/build_area_event.py

12. 파이프라인 — 지금 상태

이 자료들은 파이프라인 밖에 있다. 손으로 받아 일회성 스크립트로 넣었다. 파이프라인을 지금 돌려도 따라오지 않는다.

등록처	등록	내용
scripts/crawl_all.py	없음	주기 그룹 monthly · quarterly · semiannual · annual
scripts/run_pipeline.sh	없음	derive 목록 (파생 배치 18종)
specs/07-architecture/03-데이터-갱신주기.md	없음	주기 정보
specs/07-architecture/04-데이터-출처-크롤링-레지스트리.md	없음	출처 정보

■ 새 테이블은 기존 마스터를 안 건드렸다

7종 전부 신규 테이블이다. buildings_v6 재빌드도, 뷰 재생성도 하지 않았다. 유일한 기존 객체 변경은 master.buildings_v6(pnu) 인덱스 추가(업체를 건물에 붙일 때 전수 흠기를 막는다).

13. 갱신 주기 — 제안

원천	그쪽 갱신	증분	제안	한 번 받는 값
서울도시공간포털 고시	수시	된다	주 1회	아는 코드 나오면 멈춤
서울시 보도자료	매일	된다	주 1회	1쪽 10건
나라장터	매일	된다	주 1회	날짜 범위
도시계획시설 SHP	수시(월간)	안 됨	월 1회	전체판
LOCALDATA	매일	안 됨	월 1회	900MB · 208파일
소상공인	분기	안 됨	분기	344MB
건축HUB 인허가	분기	안 됨	분기	시군구별 파일
V-World UD602·C_UQ161	수시	안 됨	반기(현행)	전체판

고시 크롤러는 아직 증분이 아니다 — 440쪽을 다 부른다(40분). 나라장터도 마지막 받은 날짜부터 부르도록 안 고쳤다.

14. 파이프라인에서 바뀔 것

순	무엇	결과
1	도시계획시설 4종 적재	<code>area_event</code> 에 기반시설 갈래가 선다 (고시는 <code>urban_notice</code> 안에 15,084건 이미 있다)
2	건축HUB 「인허가」 3장 적재	건축 인허가 갈래가 선다. 대지위치(PNU)가 붙어 와 자리 문제가 없다
3	<code>area_event</code> 재빌드	갈래가 1개 → 4개
4	승강기 값	칸(<code>elevator_ext</code>)만 있고 값이 0건 — 마스터 재빌드로 채워진다
5	<code>master.buildings</code> 뷰 재생성	<code>elevator_ext</code> 가 뷰에 없어 API 가 못 본다. <code>DROP VIEW CASCADE</code> 가 <code>app.search_polygon</code> 을 같이 날린다 — 혼자 못 한다
6	<code>building_parcels</code> 구멍	57,228동이 pnu 는 있는데 필지 연결이 없다
7	상권 7갈래 적용	<code>buildings.py</code> 의 <code>_CAT</code> 과 <code>generate_report.py</code> 의 <code>_market_zones</code> 두 곳에 박힌 정규식을 <code>ref.biz_category</code> 로 교체. 「기타」 50.8% → 1.9%
8	원천 등록	위 4개 문서·스크립트에 크롤러와 주기를 넣는다

■ 파이프라인 없이 할 수 있는 것

무엇	상태
고시문 원문 글자 뽑기	진행 중 · 788/17,074
보도자료 3년치 백필	진행 중 · 213줄
검치는 이름 66개 고치기	미착수
고시·나라장터 증분 전환	미착수
나라장터 공고 상세에 소재지가 있는지 확인	미착수
주변 동향 ↔ 지도 아이콘	미구현